

Basket-AR: riconoscimento di azioni nella pallacanestro

Progetto di Fondamenti di Visione Artificiale e Biometria Gruppo 10

Giovanni Paolo Chierchia - Sebastiano Caliendo

Prof. Gianluca Ronga Prof. Michele Nappi Prof.ssa Lucia Cascone
Università degli Studi di Salerno
Anno Accademico 2025/2026



Obiettivo del progetto

Obiettivo: riconoscere automaticamente le azioni nei video di basket e generare un **report temporale** degli eventi rilevati.

Video RGB di
basket



Modello di action
recognition



Classe dell'azione
+ intervallo
temporale



Dataset e criticità



Dataset **custom** di clip annotate estratte da video di partite giovanili.

Dataset	Azioni target	Background	Criticità
• 9 classi iniziali • Clip annotate • Split per video	• 7 classi finali • Passaggio • Tiri per tipo/esito	• idle • non-gioco • Usate come no-action	• Azioni rapide • Occlusioni • Classi sbilanciate



Architettura generale

La pipeline è organizzata in **due flussi complementari**: classificazione di clip annotate e inferenza su video lunghi.




La **pipeline long-video riutilizza il modello finale clip-level** e lo applica su finestre temporali.



Pipeline clip-level

Il modello riceve **clip già ritagliate** e assegna una classe all'intera sequenza.




Le sequenze hanno **lunghezze diverse**: il modello deve aggregare l'informazione temporale della clip.



Feature extraction DINOv3

Ogni frame viene trasformato in una rappresentazione visuale tramite un backbone pre-addestrato.



Confronto tra feature extractor


Metriche su validation prima dell'introduzione di gerarchia e tracking.

Configurazione	Esperimento	Accuracy	Macro F1 val.
ConvNeXt-Tiny + Transformer	exp_13	0.7167	0.4557
DINOv2-L/14 + Transformer	exp_19	0.8167	0.5672
DINOv3-L/16 + Transformer	exp_22	0.8296	0.6146



Temporal Transformer

Le **feature dei singoli frame** vengono **elaborate nel tempo** per ottenere una **predizione unica sulla clip**.



Perché usarlo?

- Considera l'**evoluzione dell'azione**
- Combina **informazioni da più frame**
- Collega frame **temporalmente distanti**
- Gestisce **clip con durata variabile**

È stata testata anche **BiGRU**: con risultati iniziali simili, è stato scelto il **Temporal Transformer** per la maggiore capacità di modellare relazioni temporali tra frame distanti.



Gestione dello sbilanciamento

Il dataset è **fortemente sbilanciato**: la classe più frequente è molto più rappresentata delle classi di tiro più rare.

- Passaggio (2505 clip) ha oltre 40 volte più esempi di tiroDaTre1 (58 clip)!!

Strategie testate

- **Loss pesata**: pesi alle classi rare
- **WeightedRandomSampler**: più campioni rari
- **Augmentation tiri**: flip + color jitter




Decisioni prese

- Mantenuta **loss pesata**
- Mantenuto **sampler moderato**
- Scartata **augmentation**



Modello gerarchico

A causa dello sbilanciamento e della somiglianza tra alcune classi, il task è stato **diviso in decisioni più semplici**.



Confronto su validation con tracking aggregato:
exp_39 non gerarchico vs *exp_38* gerarchico


Modello	Accuracy	Macro F1 val.
Non gerarchico	0.8426	0.5620
Gerarchico	0.8759	0.6996

A parità di feature, la **gerarchia migliora nettamente la Macro F1**: dividere il problema in sottoproblemi più semplici aiuta il modello a gestire classi sbilanciate e tiri visivamente simili.



Tracking palla/canestro

Il **tracking palla-canestro** aggiunge informazioni esplicite su posizione, movimento e interazione palla-canestro, utili per distinguere passaggi, tiri ed esito.



Esperimento	Configurazione	Macro F1 val.
exp_31	Gerarchico senza tracking	0.5981
exp_38	Tracking aggregato su L3	0.6996
exp_40	Tracking temporale su L3	0.7223
exp_46	Tracking migliore per ciascun livello	0.8079

Il tracking migliora progressivamente la Macro F1: prima aggiunto su L3, poi in forma temporale, fino alla configurazione finale con **feature diverse per ciascun livello**



Configurazione finale clip-level

La configurazione finale combina feature DINOv3, Temporal Transformer, gerarchia e tracking pallacanestro.

Metriche standalone su validation: L2 e L3 sono valutati sui veri tiri, senza errori di routing da L1.

Livello	Task	Tracking usato	Macro F1 val.
L1	passaggio / tiro / no-action	YOLO v2 + temp43	0.9264
L2	tiroDaDue / tiroDaTre / tiroLibero	YOLO v2 + temp29	0.9095
L3	tiro0 / tiro1	YOLO v1 + temp43	0.9366

Tutti i livelli usano feature DINOv3-L/16 e Temporal Transformer; cambia il tracking scelto in base al sottoproblema.



Risultati clip-level

La configurazione finale *exp_46* è stata valutata su validation e test nella classificazione delle clip annotate.

Split	Accuracy	Macro F1	Weighted F1
Validation	0.9056	0.8079	0.9062
Test	0.8549	0.6749	0.8564

Senza distinguere l'esito del tiro: Macro F1 = **0.8744** su validation e **0.7898** su test.

Cosa funziona

- Buona accuratezza complessiva
- Macro-categorie riconosciute bene
- Modello applicabile alle clip annotate


Criticità

- Calo Macro F1 su test
- Classi rare più instabili
- Confusione **passaggio / no-action**




Pipeline long-video

In questa fase il sistema viene applicato a un video completo, con l'obiettivo di **individuare le azioni** e **generare gli eventi finali**.



Feature extraction long-video

Il video completo viene **elaborato frame per frame** per ottenere le informazioni usate poi dalle **finestre temporali**.




Le feature vengono **estratte una sola volta** e poi riutilizzate per costruire le finestre temporali.



Sliding window multi-scala

Le feature del video vengono divise in finestre temporali sovrapposte, così da **analizzare il video pezzo per pezzo**.




L'uso di più durate permette di intercettare **azioni brevi** e **azioni più lunghe**.



Classificazione delle finestre

Ogni finestra temporale viene **classificata dal modello gerarchico** per ottenere lo **score delle azioni finali**.



Le probabilità dei livelli L1, L2 e L3 **vengono combinate** per ottenere lo score delle classi finali.



Post-processing temporale

Le predizioni delle finestre non sono ancora eventi finali: il post-processing le **seleziona**, le **aggrega** e **rimuove i casi meno affidabili**.

Selezione delle predizioni

Le finestre classificate come no-action vengono scartate.

Le azioni vengono mantenute solo se superano un filtro di confidenza e risultano sufficientemente più probabili del background.

Aggregazione temporale

Predizioni vicine nel tempo e associate alla stessa classe vengono fuse in un unico evento.

Questo evita di generare più eventi per la stessa azione.

Pulizia degli eventi

Eventi troppo brevi o troppo lunghi vengono scartati o limitati.

In caso di sovrapposizioni, viene mantenuto l'evento con confidence maggiore.

Output finale: **eventi con label, start time, end time, confidence**.



Evoluzione del modello long-video

Gli esperimenti hanno cercato un compromesso tra **rilevare più azioni reali** e **ridurre i falsi positivi**.

Esperimento	Modifica chiave	Effetto osservato	F1 val.
exp_long_01	Video analizzato con molte finestre sovrapposte , anche molto brevi e fitte , per non perdere azioni reali	Alta recall, ma troppi falsi positivi	0.3649
exp_long_04	Passaggi analizzati con finestre più lunghe e durata massima controllata	Forte riduzione del rumore sui passaggi	0.5238
exp_long_09	Finestre lunghe mantenute, ma con filtro più severo tra azione e no-action	Preview più pulita e meno eventi falsi	0.5500
exp_long_10	Finestre lunghe mantenute, ma con filtro no-action reso molto più rigido	Meno falsi positivi, ma si perdono troppe azioni reali	0.5324
exp_long_13	Finestre lunghe e filtro no-action intermedio per bilanciare rumore e recall	Miglior equilibrio complessivo	0.5563
exp_long_18	Priorità controllata ai tiri quando competono con i passaggi	Tiri più visibili, ma F1 globale inferiore	0.5405

Scelta finale: *exp_long_13*, miglior compromesso tra azioni rilevate, falsi positivi e qualità della preview.



Risultati long-video

La configurazione finale ***exp_long_13*** è stata valutata a livello evento su segmenti di validation e test, usando **IoU** temporale = 0.20.

Split	GT	Pred	Precision	Recall	F1
Validation	71	80	0.5250	0.5915	0.5563
Test	123	164	0.4207	0.5610	0.4808

Cosa funziona

- Buona copertura delle azioni reali
- Output completo: label + intervallo temporale
- Pipeline utilizzabile su video continui

Criticità

- Falsi positivi ancora presenti
- Localizzazione temporale non sempre precisa
- Maggiore difficoltà rispetto alle clip ritagliate



Limiti e sviluppi futuri

Le criticità principali emergono nel passaggio dalla **classificazione di clip** alla **generazione di eventi su video lunghi**.

Limiti emersi

- **Confusione tra passaggio e no-action**
Può generare falsi eventi o far perdere azioni reali.
- **Classificazione fine dei tiri**
Alcune tipologie di tiro e il relativo esito restano difficili da distinguere.
- **Localizzazione temporale nei video lunghi**
Gli eventi non sempre vengono collocati con precisione nel tempo.
- **Sensibilità alle classi rare**
Le classi meno rappresentate sono più instabili nelle metriche.

Sviluppi futuri

- **Ampliare il dataset**
Soprattutto per le classi di tiro meno rappresentate.
- **Aumentare la varietà dei video**
Più situazioni di gioco, inquadrature e condizioni diverse.
- **Rendere il tracking più robusto**
Non solo palla e canestro, ma anche giocatori e geometria del campo.
- **Modello orientato al long-video**
Integrare meglio classificazione e localizzazione temporale.



Grazie per l'attenzione!

